

PROYECTO FINAL: Pipeline Inteligente de Análisis de Datos

OBJETIVO GENERAL

Desarrollar un pipeline completo de ETL + Machine Learning que integre todos los conocimientos adquiridos en el bootcamp, combinando múltiples fuentes de datos y aplicando técnicas de regresión lineal para generar insights de negocio.

CONTEXTO DEL PROYECTO

Utilizarás el dataset consolidado de 40 registros que generaste en el proyecto integrador del Día 1. Tu misión es expandirlo, analizarlo y crear un modelo predictivo que genere valor para la toma de decisiones empresariales.

DESCRIPCIÓN DEL RETO

ETAPA 1: Preparación de Datos (2 horas)

Punto de Partida:

- Dataset consolidado: `datos_consolidados_40_registros.csv` (del módulo 06_PROYECTO_INTEGRADO)
- Código base disponible en DIA1_ETL_FUNDAMENTALS y DIA2_ETL_ML

Tu Misión:

1. **Cargar el dataset base** y realizar análisis exploratorio inicial
2. **Investigar técnicas de Data Augmentation** para expandir el dataset de 40 a 500 registros
3. **Implementar la expansión de datos** manteniendo coherencia estadística
4. **Validar la calidad** del dataset expandido

Técnicas a Investigar:

- Generación de datos sintéticos
- Interpolación estadística
- Muestreo con variaciones controladas
- Preservación de distribuciones originales

ETAPA 2: Pipeline ETL Integrado (2 horas)

Componentes Obligatorios:

1. **EXTRACT (Extracción)**
 - Leer dataset base
 - Validar estructura de datos
 - Manejar errores de carga

2. TRANSFORM (Transformación)

- Limpiar datos inconsistentes
- Expandir dataset a 500 registros
- Crear variables derivadas
- Codificar variables categóricas

3. LOAD (Carga)

- Almacenar dataset procesado
- Generar archivo de respaldo
- Documentar transformaciones aplicadas

4. VALIDATE (Validación)

- Detectar outliers y anomalías
- Verificar integridad de datos
- Calcular métricas de calidad

ETAPA 3: Modelado y Evaluación (1.5 horas)

Modelo de Regresión Lineal:

- **Variable Objetivo:** Precio (predicción de precios de productos)
- **Variables Predictoras:** Categoría, origen, características derivadas
- **Técnicas Requeridas:**
 - Encoding de variables categóricas
 - División train/test
 - Entrenamiento del modelo
 - Evaluación con métricas (R^2 , RMSE, MAE)

Visualizaciones Obligatorias:

- Distribución de variables
- Correlaciones entre variables
- Resultados de predicción vs valores reales
- Residuos del modelo

ETAPA 4: Documentación y Presentación (30 minutos)

Entregables Finales:

1. Script integrado completo (`pipeline_inteligente.py`)
2. Dataset expandido (`datos_500_registros.csv`)
3. Documentación técnica del proceso
4. Presentación de resultados (10 minutos máximo)

ESTRUCTURA DEL ENTREGABLE

Archivo Principal: `pipeline_inteligente.py`

Debe contener TODO el código en un solo archivo con las siguientes secciones:

```
# 1. IMPORTACIÓN DE LIBRERÍAS
# 2. FUNCIONES DE EXTRACCIÓN
# 3. FUNCIONES DE TRANSFORMACIÓN Y EXPANSIÓN
# 4. FUNCIONES DE VALIDACIÓN Y CALIDAD
# 5. FUNCIONES DE MODELADO ML
# 6. FUNCIONES DE VISUALIZACIÓN
# 7. PIPELINE PRINCIPAL (main)
# 8. EJECUCIÓN AUTOMÁTICA
```

Documentación Requerida:

- Explicación de técnicas de data augmentation utilizadas
- Justificación de decisiones técnicas
- Interpretación de resultados del modelo
- Conclusiones y recomendaciones de negocio

Presentación (10 minutos):

1. Problema y contexto (2 min)
2. Proceso ETL implementado (3 min)
3. Técnica de expansión de datos (2 min)
4. Resultados del modelo (2 min)
5. Conclusiones y valor de negocio (1 min)

RECURSOS DISPONIBLES

Código Base (Ya disponible):

- **DIA1_ETL_FUNDAMENTALS:** Todos los scripts de extracción, limpieza y transformación
- **DIA2_ETL_ML:** Notebook de regresión lineal completo
- **Proyecto Integrador:** Dataset consolidado de 40 registros

Librerías Sugeridas:

```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns
from sklearn.model_selection import train_test_split
from sklearn.linear_model import LinearRegression
from sklearn.preprocessing import LabelEncoder
from sklearn.metrics import mean_squared_error, r2_score, mean_absolute_error
```

Para Investigar:

- Técnicas de data augmentation en Python

- Generación de datos sintéticos con pandas/numpy
- Validación de distribuciones estadísticas
- Mejores prácticas en pipelines ETL

CRONOGRAMA SUGERIDO

Total: 6 horas

Tiempo	Actividad	Entregable
0-2h	Investigación + Expansión de datos	Dataset 500 registros
2-4h	Desarrollo del pipeline integrado	Script funcional
4-5.5h	Modelado ML + Visualizaciones	Modelo entrenado
5.5-6h	Documentación + Preparación presentación	Documentos finales

ENTREGA FINAL

Archivos a Entregar:

1. `pipeline_inteligente.py` - Script principal completo
2. `datos_500_registros.csv` - Dataset expandido
3. `documentacion_tecnica.md` - Proceso y decisiones
4. `presentacion_resultados.pdf` - Slides de presentación
5. `graficos/` - Carpeta con visualizaciones generadas

Modalidad de Presentación:

- Exposición grupal de 10 minutos
- Sesión de preguntas y respuestas
- Evaluación entre pares (opcional)

CONSEJOS PARA EL ÉXITO

1. **Planifica tu tiempo:** No subestimes la investigación de data augmentation
2. **Reutiliza código:** Aprovecha al máximo los ejercicios anteriores
3. **Documenta mientras trabajas:** No dejes la documentación para el final
4. **Valida constantemente:** Verifica que tu dataset expandido tenga sentido
5. **Enfócate en el negocio:** Conecta tus hallazgos técnicos con valor empresarial

APOYO DISPONIBLE

- **Consultas técnicas:** Revisar documentación del Día 1 y 2
- **Recursos online:** Links y referencias proporcionados en archivo separado

Demuestra todo lo que has aprendido en un proyecto integral que combina ETL, Machine Learning y análisis de negocio.